

¿Fallan por Azar? Un Test para Sensores Industriales

Florencia Gay Merino

DNI: 43571186

9 de julio de 2025

Introducción

En la industria de procesos, los sensores de temperatura son componentes críticos cuyo fallo puede generar costosas paradas no planificadas. Una pregunta de gran interés es si la probabilidad instantánea de que un sensor falle depende o no del tiempo que lleva operando. Para ello se modela su comportamiento mediante la distribución de Weibull [1] (ver Apéndice A.1), donde el parámetro de forma k determina si las fallas son aleatorias ($k = 1$) o presentan patrones tempranos ($k < 1$).

Este trabajo aborda estadísticamente esta problemática mediante un contraste de hipótesis:

- H_0 : $k = 1$ (fallas aleatorias, distribución exponencial)
- H_1 : $k < 1$ (fallas tempranas, tasa decreciente)

Metodología

A través de simulaciones se generan muestras correspondientes a $n = 100$ sensores industriales, asumiendo dos escenarios distintos para el parámetro k . En el primer caso, bajo la hipótesis nula (H_0), se simulan fallas aleatorias ($k = 1$), mientras que en el segundo, bajo la hipótesis alternativa (H_1), fallas tempranas con un $k = 0.8$. Para obtener dicha simulación se utilizó la función `weibull_min().rvs()` del módulo `scipy.stats` y una semilla `np.random.seed(2001)` que se usará durante todo el trabajo.

La Figura 1 presenta las distribuciones empíricas obtenidas a partir de las simulaciones, representadas mediante histogramas con 30 intervalos (bins). Además, se incluyen las funciones de densidad teóricas correspondientes a cada caso.




Figura 1: Comparación entre el comportamiento bajo H_0 y H_1 : histogramas simulados y densidades teóricas.

Para contrastar las hipótesis planteadas, se utilizó un test basado en la estimación del parámetro k mediante máxima verosimilitud (MLE), tal como se detalla en el Apéndice A.2. En la práctica, esta estimación se obtuvo con la función `weibull_min.fit()` [0], fijando los parámetros `floc = 0` y `fscale = 5000` para que el ajuste se realice únicamente sobre k , manteniendo constante la escala temporal λ , obteniendo así el estimador $\hat{k}_{MLE}$ de la distribución. El procedimiento se repitió $N = 1000$ veces para construir la distribución empírica del estadístico bajo H_0 . Como era esperable, al repetirlo muchas veces, las estimaciones se agrupan y forman una distribución parecida a una campana, en línea con lo que predice el Teorema Central del Límite. Dado que en este trabajo interesa evaluar la sensibilidad del test frente a fallas tempranas, también se realizó la misma simulación pero bajo H_1 . De esta manera, fue posible estimar la potencia del test y visualizar cómo se comportan las dos hipótesis frente al mismo método de estimación. La Figura 2 muestra claramente las diferencias entre ambas distribuciones y las zonas correspondientes a los errores tipo I y tipo II.




Figura 2: Distribución del estadístico $\hat{k}_{MLE}$ bajo las hipótesis H_0 y H_1 . Se indica el valor crítico correspondiente a un nivel de significancia del 5 %, separando la región de rechazo (error tipo I) hacia la izquierda y la región de error tipo II hacia la derecha, bajo H_1 .

Resultados

La Figura 2 permite visualizar el comportamiento del estadístico $\hat{k}_{MLE}$ bajo ambas hipótesis. Las distribuciones simuladas bajo H_0 (color rosa) y H_1 (color azul) se ajustan adecuadamente a los valores de k con los que fueron generadas. En particular, se obtuvo una esperanza de $\mathbb{E}[\hat{k}_{MLE-H0}] = 1,01$, con una desviación estándar de 0,08, y de $\mathbb{E}[\hat{k}_{MLE-H1}] = 0,81$ con una desviación de 0,06, es decir, hay un solapamiento de los datos. Con estos resultados, se puede concluir que a priori es un buen método para estimar k .

El valor crítico se estimó a través de tomar un nivel de significancia al 5 % de la distribución bajo H_0 , resultando en 0,89, este número fue calculado a través de tomar el percentil 5. Una vez delimitado el valor crítico, se establece la zona de rechazo, es decir, el error tipo I, que vendría a ser todos los datos menores a 0,89. Este error corresponde a rechazar la hipótesis nula a pesar de ser verdadera.

Por otro lado, se definió β como la media de los datos bajo H_1 que son mayores al valor crítico calculado previamente, resultando en $\beta \approx 0,09$. Luego se establece la zona de error tipo II. Dicho error se refiere a rechazar la hipótesis alternativa siendo que era cierta.

Posteriormente, se evaluó la potencia del test $(1 - \beta)$ para distintos valores de $k < 1$, con el objetivo de caracterizar su sensibilidad ante diversas alternativas. Los resultados se presentan en la Figura 3, donde se observa que la potencia es elevada para valores de $k \leq 0,75$ disminuyendo progresivamente a medida que k se aproxima a 1. A partir de $k = 0,9$, por ejemplo, la potencia ya se encuentra por debajo del 50 %, lo que sugiere un riesgo considerable de error tipo II en situaciones limítrofes.




Figura 3: Curva de potencia del test para distintos valores de k . Se observa alta sensibilidad ante fallas tempranas (valores bajos de k).

Además, se analizaron los p -valores simulados bajo dos escenarios distintos. La Figura 4 muestra su distribución para $k = 0,9$, mientras que la Figura 5 corresponde a $k = 1$. En el primer caso, el valor de significancia más bajo para el cual no se rechaza H_0 fue de aproximadamente 0,136, lo que indica que con niveles menores a este valor, el test tiende a rechazar correctamente la hipótesis nula.

Es interesante analizar los resultados, ya que demuestra que bajo la hipótesis nula, si calculo el p -valor para un $k = 1$ se vuelve uniforme como era de esperarse.




Figura 4: Distribución de p -valores simulados bajo H_1 con $k = 0,9$.




Figura 5: Distribución de p -valores simulados bajo H_0 con $k = 1$.

Conclusión

El estimador de k obtenido por máxima verosimilitud demostró ser una herramienta muy precisa para este tipo de distribución: logra estimar bien el valor verdadero con baja dispersión, y permite distinguir claramente entre escenarios distintos (como $k = 1$ y $k = 0,8$) gracias a la separación entre las curvas resultantes.

En cuanto a la potencia del test, se confirmó que con un nivel de significancia del 5 %, el método es altamente efectivo para detectar fallas tempranas cuando $k \leq 0,75$, y aún se mantiene por encima del 60 % de potencia incluso cuando $k = 0,85$, lo cual lo hace bastante sólido para casos intermedios.

Por otro lado, el análisis de p -valores reforzó la validez del enfoque. Bajo H_0 , la distribución de los p -valores resultó ser prácticamente uniforme en $[0, 1]$, como se espera teóricamente si el test está bien calibrado. Esto deja en claro que el procedimiento no solo tiene buena sensibilidad, sino que además respeta correctamente el nivel de significancia planteado.

Referencias

- [1] Weibull distribution. (2023). In *Wikipedia*. https://en.wikipedia.org/wiki/Weibull_distribution
- [2] SciPy. (2024). *scipy.stats.weibull_min*. Disponible en: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.weibull_min.html

A Apéndice

A.1 Distribución de Weibull

La función de densidad de probabilidad es:

$$f(t; \lambda, k) = \frac{k}{\lambda} \left(\frac{t}{\lambda} \right)^{k-1} e^{-(t/\lambda)^k} \quad (1)$$

donde:

- $t \geq 0$: tiempo hasta la falla
- $\lambda > 0$: parámetro de escala (5000 horas)
- $k > 0$: parámetro de forma

A.2 Estimación por Máxima Verosimilitud (MLE)

El estimador de máxima verosimilitud $\hat{k}$ se obtiene maximizando la siguiente log-verosimilitud sobre una muestra de tamaño n :

$$\log L(k) = n \log k - nk \log \lambda + (k-1) \sum_{i=1}^n \log t_i - \sum_{i=1}^n \left(\frac{t_i}{\lambda} \right)^k \quad (2)$$

En este trabajo, dicha estimación se realizó utilizando la función `weibull_min.fit()` de la librería `scipy.stats` [2].